

AI Cheat Sheet: Keyword → Solution

Đọc đề, bắt từ khóa, chọn công nghệ phù hợp, viết một câu trả lời

Tìm: chatbot, sai, chậm, tài liệu, ROI, Docker, tuyển dụng...

- Tất cả
- Chatbot
- Agent
- An toàn
- Vận hành
- Dữ liệu
- Business

Mẹo làm bài: không cần liệt kê nhiều. Nêu đúng **vấn đề** → **giải pháp** → **mục đích**. Ví dụ: “Vì chatbot cần trả lời từ tài liệu nội bộ, tôi dùng RAG để tìm đoạn liên quan trước khi LLM trả lời.”

Hiển thị 31/31 tình huống.

KEYWORD / TÌNH HUỐNG TRONG ĐỀ	DÙNG SOLUTION NÀO?	CÂU TRẢ LỜI DỄ NHỚ
Chatbot hỏi đáp từ tài liệu công ty Chatbot	RAG + Vector DB	Dùng RAG để chatbot tìm đoạn tài liệu rồi mới dùng LLM trả lời, nên câu trả lời nguồn hơn.
Người dùng hỏi khác chữ nhưng cùng ý Chatbot	Embedding + Vector Search	Dùng embedding để tìm theo ý nghĩa, và tài liệu có thể không trùng từ nhưng nội dung.
Tài liệu quá dài, chatbot lấy thiếu ý Chatbot	Chunking + Metadata	Chia tài liệu thành các đoạn theo mục/lưu metadata để chatbot lấy đúng đoạn nguồn.
Có tài liệu cũ và mới Chatbot	Metadata Filter	Gắn ngày hiệu lực/phần bản rồi lọc tài trước khi RAG tìm kiếm.
Chatbot bịa, trả lời không có trong tài liệu Chatbot	RAG + Citation + Guardrail	Buộc chatbot trả lời kèm nguồn; không thì nói không biết thay vì tự bịa.
Chatbot phải nhớ cuộc trò chuyện trước Chatbot	Memory + Summary	Lưu lịch sử ngắn hạn và tóm tắt đoạn c ngữ cảnh mà không làm prompt quá d
Chatbot phải trả về form/JSON để hệ thống xử lý Chatbot	Output Contract + Validation	Ép AI trả đúng JSON theo schema và k trước khi hệ thống dùng kết quả.

KEYWORD / TÌNH HUỐNG TRONG ĐỀ	DÙNG SOLUTION NÀO?	CÂU TRẢ LỜI DỄ NHỚ
Cần chatbot trả lời nhiều ngôn ngữ Chatbot	Multilingual LLM	Dùng LLM đa ngôn ngữ và kiểm tra riêng lượng tiếng Việt/các ngôn ngữ cần hỗ trợ.
AI cần tra cứu, tính toán hoặc gọi API Agent	Single Agent + Tools	Dùng một agent gọi các tool cần thiết; khi quy trình còn đơn giản và dễ kiểm soát.
Nhiều việc/chuyên môn phải chạy song song Agent	Multi-Agent + Orchestrator	Dùng multi-agent khi các vai trò tách rời, cần orchestrator điều phối để agent không xung đột.
Agent gọi tool lặp vô tận Agent	Max Iterations + Retry Limit	Giới hạn số lần chạy và dừng agent khi vượt ngưỡng để tránh loop và tốn chi phí.
Agent làm việc quan trọng như gửi tiền/xóa dữ liệu Agent	Guardrail + HITL	Chỉ cho agent quyền cần thiết và yêu cầu con người duyệt trước các hành động có rủi ro cao.
Tài liệu cố lừa AI bỏ qua quy tắc An toàn	Input Guardrail + Context Isolation	Lọc câu lệnh lạ và coi tài liệu chỉ là dữ liệu, không cho nó thay đổi hướng dẫn hệ thống.
Có email, số điện thoại, CV trong dữ liệu An toàn	Masking + RBAC + TTL	Che dữ liệu nhạy cảm, chỉ người có quyền xem và tự xóa log sau thời hạn cần thiết.
Khách A không được thấy dữ liệu khách B An toàn	Tenant Filter + RBAC	Gắn tenant_id và lọc cứng tenant_id khi truy vấn để ngăn rò rỉ chéo khách hàng.
AI dùng cho tuyển dụng/chấm điểm con người An toàn	HITL + Bias Check	Không để AI tự quyết định; dùng AI hỗ trợ con người duyệt, đồng thời kiểm tra thiên lệch.
AI phản hồi chậm, người dùng chờ lâu Vận hành	Tracing + Cache + Scaling	Đo xem chậm ở đâu, cache câu hỏi phổ biến, mới tăng máy khi cần.
Lượng người dùng tăng đột biến Vận hành	Load Balancer + Auto Scaling	Chia tải qua nhiều máy và tự tăng/giảm theo traffic.

KEYWORD / TÌNH HUỐNG TRONG ĐỀ	DÙNG SOLUTION NÀO?	CÂU TRẢ LỜI DỄ NHỚ
Chi phí LLM tăng cao Vận hành	Token Limit + Cache + Smaller Model	Giảm prompt/token thừa, cache kết quả, dùng model nhỏ cho việc đơn giản để giảm chi phí.
Muốn đưa AI lên production an toàn Vận hành	Docker + CI/CD + Monitoring	Đóng gói bằng Docker, tự động test/deploy bằng CI/CD và theo dõi lỗi để rollback khi cần.
Bản prompt/model mới có thể làm AI kém đi Vận hành	Evaluation + Canary Deploy	Test trên bộ câu hỏi chuẩn và chỉ mở rộng dần dùng trước khi triển khai toàn bộ.
Không biết chatbot sai vì tìm tài liệu hay vì LLM Vận hành	Recall + Faithfulness	Đo Recall để biết có tìm đúng tài liệu không, đo Faithfulness để biết AI có bám tài liệu không.
Dữ liệu/tài liệu thay đổi mỗi ngày Dữ liệu	Ingestion Pipeline + Re-index	Tự động nạp tài liệu mới và cập nhật index, AI có kiến thức mới mà không phải train lại.
Tác vụ chạy lâu, không muốn người dùng chờ Dữ liệu	Queue + Worker	Đưa việc vào hàng đợi để worker xử lý, người dùng nhận phản hồi ngay.
Xử lý dữ liệu/sự kiện realtime Dữ liệu	Kafka + Consumer Group	Dùng Kafka để nhận luồng sự kiện và phân phối cho consumer xử lý song song khi dữ liệu tăng.
AI tạo SQL từ câu hỏi tự nhiên Dữ liệu	Text-to-SQL + Read-only	Cho AI quyền chỉ đọc và kiểm tra SQL trước khi chạy để không xóa hoặc lộ dữ liệu.
Cần báo cáo từ dữ liệu đã làm sạch Dữ liệu	Data Warehouse/Lakehouse	Đưa dữ liệu qua ETL/ELT vào Warehouse/Lakehouse để báo cáo và AI dùng dữ liệu sạch.
Pilot AI đúng nhưng nhân viên không dùng Business	UX + Workflow Integration	Kiểm tra AI có dễ dùng, có nằm trong workflow hay không, đào tạo và có thực sự tiết kiệm thời gian không.
Cần tính ROI chatbot Business	ROI Formula + Usage Metrics	Tính lợi ích từ số giờ tiết kiệm trừ chi phí vận hành, rồi chia cho chi phí; theo dõi adoption và cost/query.

KEYWORD / TÌNH HUỐNG TRONG ĐỀ	DÙNG SOLUTION NÀO?	CÂU TRẢ LỜI DỄ NHỚ
Chọn use case AI đầu tiên Business	Pilot + KPI	Chọn việc lặp lại, có dữ liệu và giá trị rõ ràng trước rồi đo KPI để quyết định scale.
Luật AI chưa hoàn thiện Business	Risk-Based Governance	Quản trị theo mức rủi ro: có policy, người chịu trách nhiệm, kiểm tra dữ liệu và audit log để mở rộng.