



Workshop Tổng Hợp – Full Production Agent System

AICB-P2T3 · Ngày 28 · Chương 6 – Agent trong Production

Giảng viên

VinUniversity · Phase 2 · Track 3 · Tuần 6


“Một AI agent production-ready trông như thế nào – kiến trúc, eval, guardrails, và HITL?”

Giữ câu hỏi này trong đầu suốt buổi học hôm nay


1. Kiến trúc toàn cảnh – Review N16–N27
2. Production Readiness Checklist
3. Benchmark Framework
4. Documentation Standards
5. Peer Review Process
6. Hands-on Integration Sprint
7. Live Demo & Milestone 3

Kiến trúc toàn cảnh – Review N16–N27


Nhìn lại tất cả components đã build trong 12 buổi



Ghép tất cả layers thành **một hệ thống hoạt động end-to-end**. Không build mới – chỉ integrate, test, và polish.



Lưu ý: Integration bugs thường xảy ra ở **ranh giới giữa components** – format mismatch, missing error handling, timeout không đồng bộ. Hôm nay tập trung vào các “seams” này.



Production Readiness Check- list

Hệ thống đã sẵn sàng production chưa?

Functional

- ☒ All user scenarios tested (happy + edge cases)
- ☒ RAGAS Faithfulness ≥ 0.80 , Answer Relevancy ≥ 0.80
- ☒ Guardrail true positive rate $> 95\%$
- ☒ Multi-agent handoff tested (3+ agent types)
- ☐ Stress test: 50 concurrent queries

Reliability

- ☒ Circuit breaker chaos test: 99.5% SLA
- ☒ Multi-provider fallback verified (OpenAI $\rightarrow$ Claude)
- ☒ Semantic cache hit rate measured
- ☐ Recovery time $< 5s$ after provider failure

Security

- ☒ PII detection guardrail active
- ☒ Prompt injection blocked (10 adversarial tests)
- ☒ MCP OAuth 2.0 authentication
- ☒ Audit trail immutable (append-only PostgreSQL)

Observability


- ☒ LangSmith traces cho mọi agent run
- ☐ Prometheus metrics + Grafana dashboard
- ☐ Alert rules: latency P95 > 10s, error rate > 5%

Documentation

- ☒ Architecture Decision Records (ADRs)
- ☐ Runbook: key rotation, KB update, incident response
- ☐ API specs: OpenAPI + MCP tool schemas

Benchmark Framework

Đánh giá toàn diện hệ thống – không chỉ accuracy



Do cost reduction **with vs without** semantic cache.
Typical: 30–60% token savings
trên repeated queries.

Trace latency per component để
identify bottleneck.
RAG retrieval thường chiếm 40–
60% total latency.

Metric	Target	Actual	Status
RAGAS Faithfulness	≥ 0.80	—	☐
Answer Relevancy	≥ 0.80	—	☐
Latency P95	$< 8s$	—	☐
Token cost / query	$< \$0.05$	—	☐
Circuit breaker SLA	$\geq 99.5\%$	—	☐
Guardrail TP rate	$> 95\%$	—	☐
Cache hit rate	$> 40\%$	—	☐

Điền bảng này với số liệu thực từ hệ thống của bạn. Benchmark report = bằng chứng hệ thống hoạt động.

Documentation Standards

Hệ thống không document thì không maintain được

ADRs

Why Reflexion not LATS?

Why DPO not RLHF?

Why PostgreSQL not MongoDB?

Future maintainers cần tradeoff context.

Runbook

Rotate API keys

Update knowledge base

Retrain LoRA adapter

Incident guide:

Circuit breaker tripped?

→ Step-by-step response

API Specs

OpenAPI spec

MCP tool schemas

Example requests

Example responses


Consumers self-serve without asking dev team.

Lưu ý: System phải **maintainable** bởi người không build nó. Nếu chỉ bạn hiểu cách hệ thống hoạt động, đó là technical debt, không phải expertise.

Peer Review Process

Swap codebase, review theo checklist, cho feedback actionable

05



Review format:

- **3 strengths:** cụ thể, có dẫn chứng
- **3 improvements:** actionable, có ví dụ
- **1 architecture question:** “Tại sao chọn X thay vì Y?”

Code quality & readability
Eval completeness (RAGAS scores)
Reliability (fallback, error handling)
Documentation (ADRs, runbook)

Hands-on Integration Sprint

Thời gian chính: ghép components, test, benchmark, và document

Mục tiêu: Integrate tất cả components thành Full Production Agent System

Deliverable: GitHub repo (documented, CI) + benchmark report + peer review feedback + demo video

Thời gian: 90 phút

1. **Connect components:** Agent Core → Memory → GraphRAG → MCP Tools
2. **Wire guardrails:** Input validation → PII detection → Output guardrails
3. **Add HITL gates:** interrupt_before cho delete/deploy, confidence routing
4. **Circuit breaker:** wrap LLM calls, configure fallback provider

Lưu ý: Integration bugs thường ở **data format mismatches** giữa components. Validate interface contracts trước khi test E2E.

1. **E2E test:** chạy 50-question test set, đo RAGAS scores
2. **Chaos test:** tắt OpenAI mid-run, verify circuit breaker + fallback
3. **Latency profiling:** trace per-component, identify bottleneck
4. **Fill benchmark report:** điền bảng metrics với số liệu thực

Benchmark report hoàn chỉnh – bảng metrics có actual numbers, không phải “TBD”

Mục tiêu: Peer Review: swap codebase, review theo checklist, viết feedback

Deliverable: Structured feedback: 3 strengths + 3 improvements + 1 architecture question

Thời gian: 30 phút

1. **Swap:** đổi repo URL với pair partner
2. **Clone & Run:** `git clone` → `docker compose up` → test demo
3. **Review:** theo 4 dimensions (code, eval, reliability, docs)
4. **Feedback:** viết 3+3+1 format, submit qua Notion

Incorporate **top-3 suggestions** từ peer review vào codebase trước Milestone 3 submission. Demonstrate **feedback responsiveness**.

Live Demo & Milestone 3

Full system demo + submission requirements

07

1. Task: “Analyze AI safety papers, summarize, identify problems, tạo action items”
2. Full stack: multi-agent delegation, GraphRAG retrieval, guardrail check
3. HITL: approval interrupt khi agent muốn create GitHub issue (confidence 68%)
4. Reliability: disable OpenAI mid-demo → circuit breaker → Claude fallback → uninterrupted

1

GitHub Repo
Documented
CI/CD
All components

Notion Portfolio
Architecture
Benchmark
ADRs

3

Demo Video
10 minutes
Full E2E
Chaos test

4

Reflection
500 words
Hardest part
What proud of

Bắt đầu bằng architecture overview

Show happy path + edge case

Show chaos test (provider failure)

End with metrics dashboard

What was the hardest integration?

What would you do differently?

What are you most proud of?

Deadline: end of N28 lab

Những ý chính cần nhớ sau buổi học hôm nay

- 1 Production agent = tổng hợp nhiều quyết định nhỏ được làm đúng – không có “phần khó” duy nhất
- 2 Benchmarking reveals surprises – hệ thống “chạy tốt trên máy dev” thường có integration issues
- 3 Documentation là first-class deliverable – undocumented system cannot be maintained
- 4 Peer review + feedback incorporation = kỹ năng production thực tế, không chỉ bài tập

Ngày 29: Thi Midterm – Lý Thuyết + Demo Agent System

“Bạn có thể giải thích kiến trúc agent của mình – và defend các quyết định thiết kế không?”

- Submit Milestone 3 trước deadline
- Chuẩn bị demo 10 phút + defend architecture decisions
- Ôn lý thuyết N16–N28: patterns, tradeoffs, benchmarks

Hỏi & Đáp

Hệ thống production-ready thật sự cần gì – ngoài “code chạy được”?



Cảm ơn!

AICB-P2T3 · Ngày 28 · Workshop Tổng
Hợp – Full Production Agent System

github.com/vinuni-aicb

Liên hệ: instructor@vinuni.edu.vn